



UNIVERSIDADE
FEDERAL DO CEARÁ



Aprendizagem de Máquina Probabilística

César Lincoln Cavalcante Mattos

2025

Agenda

- ① Modelo beta-binomial
- ② Modelo Dirichlet-multinomial
- ③ Classificador naive Bayes
- ④ Tópicos adicionais
- ⑤ Referências

Modelo beta-binomial

- Considere N lançamentos de uma moeda com probabilidade θ de ser cara ($X = 1$) e $1 - \theta$ de ser coroa ($X = 0$).

Modelo beta-binomial

- Considere N lançamentos de uma moeda com probabilidade θ de ser cara ($X = 1$) e $1 - \theta$ de ser coroa ($X = 0$).
- **Problema:** como caracterizar θ a partir de N observações disponíveis $x_i|_{i=1}^N$?

Modelo beta-binomial

- Seguimos o procedimento padrão de modelagem:

$$p(\mathcal{D}|\theta) \rightarrow \text{verossimilhança}$$

$$p(\theta) \rightarrow \text{priori}$$

$$p(\theta|\mathcal{D}) \rightarrow \text{posteriori}$$

Modelo beta-binomial

- Seguimos o procedimento padrão de modelagem:

$$p(\mathcal{D}|\theta) \rightarrow \text{verossimilhança}$$

$$p(\theta) \rightarrow \text{priori}$$

$$p(\theta|\mathcal{D}) \rightarrow \text{posteriori}$$

- Solução de **máxima verossimilhança (ML)**:

$$\theta_{ML} = \arg \max p(\mathcal{D}|\theta).$$

- Solução de **máximo a posteriori (MAP)**:

$$\theta_{MAP} = \arg \max p(\theta|\mathcal{D}) = \arg \max p(\mathcal{D}|\theta)p(\theta).$$

- Solução **Bayesiana**:

$$p(\theta|\mathcal{D}) = \frac{p(\mathcal{D}|\theta)p(\theta)}{p(\mathcal{D})} = \frac{p(\mathcal{D}|\theta)p(\theta)}{\int p(\mathcal{D}|\theta)p(\theta)d\theta}.$$

Modelo beta-binomial

- Considere N lançamentos de uma moeda com probabilidade θ de ser cara ($X = 1$) e $1 - \theta$ de ser coroa ($X = 0$).

Modelo beta-binomial

- Considere N lançamentos de uma moeda com probabilidade θ de ser cara ($X = 1$) e $1 - \theta$ de ser coroa ($X = 0$).
- A **verossimilhança** desse experimento pode ser escrita por:

$$x_i \sim \text{Ber}(\theta),$$

$$p(\mathcal{D}|\theta) = \prod_{i=1}^N \theta^{x_i} (1-\theta)^{1-x_i} = \theta^{N_1} (1-\theta)^{N-N_1},$$

$$N_1 = \sum_{i=1}^N \mathbb{I}(x_i = 1).$$

Modelo beta-binomial

- Considere N lançamentos de uma moeda com probabilidade θ de ser cara ($X = 1$) e $1 - \theta$ de ser coroa ($X = 0$).
- A **verossimilhança** desse experimento pode ser escrita por:

$$x_i \sim \text{Ber}(\theta),$$

$$p(\mathcal{D}|\theta) = \prod_{i=1}^N \theta^{x_i} (1-\theta)^{1-x_i} = \theta^{N_1} (1-\theta)^{N-N_1},$$

$$N_1 = \sum_{i=1}^N \mathbb{I}(x_i = 1).$$

- Podemos escrever a probabilidade do número de caras:

$$p(N_1 = k) = \text{Bin}(k|N, \theta) = \binom{N}{k} \theta^k (1-\theta)^{N-k}.$$

- Note que o termo $\binom{N}{k}$ não depende de θ .
- θ pode ser inferido com $\mathcal{D} = (N_1, N)$ ou $\mathcal{D} = (x_1, \dots, x_N)$.

Modelo beta-binomial

- Podemos escolher uma **priori conjugada** para $\theta \in [0, 1]$, i.e., a **distribuição beta**:

$$p(\theta) = \text{Beta}(\theta | a, b) = \frac{\Gamma(a + b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1 - \theta)^{b-1},$$

em que $a, b > 0$ são hiperparâmetros.

Modelo beta-binomial

- Podemos escolher uma **priori conjugada** para $\theta \in [0, 1]$, i.e., a **distribuição beta**:

$$p(\theta) = \text{Beta}(\theta | a, b) = \frac{\Gamma(a + b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1 - \theta)^{b-1},$$

em que $a, b > 0$ são hiperparâmetros.

- Nesse caso, a **posteriori** é analítica:

$$\begin{aligned} p(\theta | \mathcal{D}) &= \frac{p(\mathcal{D} | \theta)p(\theta)}{p(\mathcal{D})} \\ p(\theta | \mathcal{D}) &\propto p(\mathcal{D} | \theta)p(\theta) \\ &\propto \theta^{N_1} (1 - \theta)^{N - N_1} \theta^{a-1} (1 - \theta)^{b-1} \\ &\propto \theta^{N_1 + a - 1} (1 - \theta)^{N - N_1 + b - 1} \\ &= \text{Beta}(\theta | N_1 + a, N - N_1 + b). \end{aligned}$$

Modelo beta-binomial

- As soluções MAP, ML, média e variância da posteriori beta são:

$$\theta_{\text{MAP}} = \frac{a + N_1 - 1}{a + b + N - 2}, \quad \theta_{\text{ML}} = \frac{N_1}{N},$$

$$\mathbb{E}[\theta | \mathcal{D}] = \frac{a + N_1}{a + b + N},$$

$$\mathbb{V}[\theta | \mathcal{D}] = \frac{(a + N_1)(b + N - N_1)}{(a + b + N)^2(a + b + N + 1)}.$$

Modelo beta-binomial

- As soluções MAP, ML, média e variância da posteriori beta são:

$$\theta_{\text{MAP}} = \frac{a + N_1 - 1}{a + b + N - 2}, \quad \theta_{\text{ML}} = \frac{N_1}{N},$$

$$\mathbb{E}[\theta|\mathcal{D}] = \frac{a + N_1}{a + b + N},$$

$$\mathbb{V}[\theta|\mathcal{D}] = \frac{(a + N_1)(b + N - N_1)}{(a + b + N)^2(a + b + N + 1)}.$$

- A distribuição preditiva, i.e., probabilidade da próxima observação ser cara ($x_* = 1$), também é analítica:

$$\begin{aligned} p(x_* = 1|\mathcal{D}) &= \int_0^1 p(x_* = 1|\theta)p(\theta|\mathcal{D})d\theta \\ &= \int_0^1 \theta \text{Beta}(\theta|N_1 + a, N - N_1 + b)d\theta = \mathbb{E}[\theta|\mathcal{D}]. \end{aligned}$$

Modelo beta-binomial

- A distribuição preditiva do número de caras obtidas nas próximas M observações ($\hat{a} = N_1 + a$ e $\hat{b} = N - N_1 + b$) é dada por:

$$\begin{aligned} p(k|\mathcal{D}, M) &= \int_0^1 \text{Bin}(k|M, \theta) \text{Beta}(\theta|\hat{a}, \hat{b}) d\theta \\ &= \binom{M}{k} \frac{\Gamma(\hat{a} + \hat{b})}{\Gamma(\hat{a})\Gamma(\hat{b})} \int_0^1 \theta^k (1-\theta)^{M-k} \theta^{\hat{a}-1} (1-\theta)^{\hat{b}-1} d\theta \\ &= \binom{M}{k} \frac{\Gamma(\hat{a} + \hat{b})}{\Gamma(\hat{a})\Gamma(\hat{b})} \int_0^1 \theta^{k+\hat{a}-1} (1-\theta)^{M-k+\hat{b}-1} d\theta \\ &= \binom{M}{k} \frac{\Gamma(\hat{a} + \hat{b})}{\Gamma(\hat{a})\Gamma(\hat{b})} \frac{\Gamma(k+\hat{a})\Gamma(M-k+\hat{b})\Gamma(M+1)}{\Gamma(k+1)\Gamma(M-k+1)\Gamma(M+\hat{a}+\hat{b})} \\ &= \text{Bb}(k|\hat{a}, \hat{b}, M) \quad (\text{distribuição beta-binomial}). \end{aligned}$$


Modelo beta-binomial

- A distribuição preditiva do número de caras obtidas nas próximas M observações ($\hat{a} = N_1 + a$ e $\hat{b} = N - N_1 + b$) é dada por:

$$\begin{aligned} p(k|\mathcal{D}, M) &= \int_0^1 \text{Bin}(k|M, \theta) \text{Beta}(\theta|\hat{a}, \hat{b}) d\theta \\ &= \binom{M}{k} \frac{\Gamma(\hat{a} + \hat{b})}{\Gamma(\hat{a})\Gamma(\hat{b})} \int_0^1 \theta^k (1-\theta)^{M-k} \theta^{\hat{a}-1} (1-\theta)^{\hat{b}-1} d\theta \\ &= \binom{M}{k} \frac{\Gamma(\hat{a} + \hat{b})}{\Gamma(\hat{a})\Gamma(\hat{b})} \int_0^1 \theta^{k+\hat{a}-1} (1-\theta)^{M-k+\hat{b}-1} d\theta \\ &= \binom{M}{k} \frac{\Gamma(\hat{a} + \hat{b})}{\Gamma(\hat{a})\Gamma(\hat{b})} \frac{\Gamma(k+\hat{a})\Gamma(M-k+\hat{b})\Gamma(M+1)}{\Gamma(k+1)\Gamma(M-k+1)\Gamma(M+\hat{a}+\hat{b})} \\ &= \text{Bb}(k|\hat{a}, \hat{b}, M) \quad (\text{distribuição beta-binomial}). \end{aligned}$$


- Temos ainda que $\mathbb{E}[k|\mathcal{D}] = M \frac{\hat{a}}{\hat{a} + \hat{b}}$ e $\mathbb{V}[k|\mathcal{D}] = \frac{M\hat{a}\hat{b}}{(\hat{a} + \hat{b})^2} \frac{\hat{a} + \hat{b} + M}{\hat{a} + \hat{b} + 1}$.

Modelo beta-binomial



Modelo beta-binomial

$$\theta_{ML} = 0.20, \theta_{MAP} = 0.25, E[\theta|D] = 0.29, V[\theta|D] = 1.36e-02$$




$$p(\theta) = \text{Beta}(\theta|a = 2, b = 2),$$

$$p(N_1 = k) = \text{Bin}(k|N, \theta), \quad k = 2, N = 10,$$

$$p(\theta|D) = \text{Beta}(\theta|a = 4, b = 10).$$


Modelo beta-binomial - solução MAP

Predictive distribution of the number of 1's after more 10 observations
Binomial MAP prediction - $E[k|D] = 2.5$



Modelo beta-binomial - solução Bayesiana

Predictive distribution of the number of 1's after more 10 observations
Bayesian Beta-binomial prediction - $E[k|D] = 2.9$



Agenda

- ① Modelo beta-binomial
- ② Modelo Dirichlet-multinomial
- ③ Classificador naive Bayes
- ④ Tópicos adicionais
- ⑤ Referências

Modelo Dirichlet-multinomial

- Considere N lançamentos de um dado com K faces.
- A k -ésima face tem probabilidade θ_k de ser observada.
- A verossimilhança desse experimento pode ser escrita por:

$$p(x_1, x_2, \dots, x_N | \boldsymbol{\theta}) = \prod_{k=1}^K \theta_k^{N_k},$$
$$N_k = \sum_{i=1}^N \mathbb{I}(x_i = k), \quad \sum_{k=1}^K \theta_k = 1.$$

Modelo Dirichlet-multinomial

- Considere N lançamentos de um dado com K faces.
- A k -ésima face tem probabilidade θ_k de ser observada.
- A verossimilhança desse experimento pode ser escrita por:

$$p(x_1, x_2, \dots, x_N | \boldsymbol{\theta}) = \prod_{k=1}^K \theta_k^{N_k},$$
$$N_k = \sum_{i=1}^N \mathbb{I}(x_i = k), \quad \sum_{k=1}^K \theta_k = 1.$$

- Alternativamente poderíamos usar a **distribuição multinomial**:

$$p(N_1, N_2, \dots, N_k | \boldsymbol{\theta}) = \binom{N}{N_1, \dots, N_k} \prod_{k=1}^K \theta_k^{N_k}$$
$$= \frac{N!}{N_1! N_2! \cdots N_k!} \prod_{k=1}^K \theta_k^{N_k}.$$

Modelo Dirichlet-multinomial

- Escolhemos uma **priori conjugada** para $\boldsymbol{\theta} \mid \theta_k \in [0, 1]$, a **distribuição de Dirichlet**:

$$p(\boldsymbol{\theta}) = \text{Dir}(\boldsymbol{\theta} | \boldsymbol{\alpha}) = \frac{\Gamma(\alpha_1 + \dots + \alpha_K)}{\Gamma(\alpha_1) \cdots \Gamma(\alpha_K)} \prod_{k=1}^K \theta_k^{\alpha_k - 1},$$

em que $\alpha_1, \dots, \alpha_k > 0$ são hiperparâmetros.

- Nesse caso a posteriori é analítica:


$$p(\boldsymbol{\theta} | \mathcal{D}) \propto p(\mathcal{D} | \boldsymbol{\theta}) p(\boldsymbol{\theta}) \propto \prod_{k=1}^K \theta_k^{N_k} \prod_{k=1}^K \theta_k^{\alpha_k - 1} = \prod_{k=1}^K \theta_k^{N_k + \alpha_k - 1},$$

$$p(\boldsymbol{\theta} | \mathcal{D}) = \text{Dir}(\boldsymbol{\theta} | \boldsymbol{\alpha} + \mathbf{N}), \quad \mathbf{N} = [N_1, \dots, N_K]^\top.$$

- A média e a variância são dadas por:

$$\mathbb{E}[\theta_k | \mathcal{D}] = \frac{\alpha_k + N_k}{N + \sum_{k=1}^K \alpha_k}, \quad \mathbb{V}[\theta_k | \mathcal{D}] = \frac{\frac{\alpha_k}{\sum_{k=1}^K \alpha_k} \left(1 - \frac{\alpha_k}{\sum_{k=1}^K \alpha_k}\right)}{1 + \sum_{k=1}^K \alpha_k}.$$

Modelo Dirichlet-multinomial



Distribuição de Dirichlet sobre 3 variáveis. Da esquerda para direita:
 $\alpha_k = 0.1$, $\alpha_k = 1$ e $\alpha_k = 10$

Modelo Dirichlet-multinomial

- A solução MAP $\boldsymbol{\theta}_{\text{MAP}}$ deve ser obtida maximizando $p(\mathcal{D}|\boldsymbol{\theta})p(\boldsymbol{\theta})$ (ou seu logaritmo).
- Usamos um **Lagrangiano** com a restrição de $\sum_{k=1}^K \theta_k = 1$:

$$\boldsymbol{\theta} = \arg \max \log p(\mathcal{D}|\boldsymbol{\theta})p(\boldsymbol{\theta}), \text{ s.a.}$$

$$\begin{aligned}\mathcal{L}(\boldsymbol{\theta}, \lambda) &= \log \prod_{k=1}^K \theta_k^{N_k + \alpha_k - 1} + \lambda \left(1 - \sum_{k=1}^K \theta_k \right) \\ &= \sum_{k=1}^K (N_k + \alpha_k - 1) \log \theta_k + \lambda \left(1 - \sum_{k=1}^K \theta_k \right),\end{aligned}$$

em que $\lambda \in \mathbb{R}$ é um **multiplicador de Lagrange**.

Modelo Dirichlet-multinomial

- Calculamos $\frac{\partial \mathcal{L}(\boldsymbol{\theta}, \lambda)}{\partial \theta_k} = 0$:

$$\frac{\partial \mathcal{L}(\boldsymbol{\theta}, \lambda)}{\partial \theta_k} = \frac{N_k + \alpha_k - 1}{\theta_k} - \lambda = 0.$$
$$\lambda \theta_k = N_k + \alpha_k - 1.$$

- Como $\sum_{k=1}^K \theta_k = 1$, temos:

$$\lambda = \sum_{k=1}^K (N_k + \alpha_k - 1) = N + \alpha_0 - K, \quad \text{em que } \alpha_0 = \sum_{k=1}^K \alpha_k.$$

- O máximo do Lagrangiano então será:

$$[\boldsymbol{\theta}_{\text{MAP}}]_k = \frac{N_k + \alpha_k - 1}{N + \alpha_0 - K}.$$

- Para $\alpha_k = 1$ (priori uniforme), obtemos a solução de máxima verossimilhança:

$$[\boldsymbol{\theta}_{\text{ML}}]_k = N_k / N.$$

Modelo Dirichlet-multinomial

- A distribuição preditiva, i.e., a probabilidade da próxima observação ser $x_* = k$, também é analítica:

$$\begin{aligned} p(x_* = k | \mathcal{D}) &= \int p(x_* = k | \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathcal{D}) d\boldsymbol{\theta} \\ &= \int p(x_* = k | \theta_k) \left[\int p(\boldsymbol{\theta}_{-k}, \theta_k | \mathcal{D}) d\boldsymbol{\theta}_{-k} \right] d\theta_k \\ &= \int \theta_k p(\theta_k | \mathcal{D}) d\theta_k \\ &= \mathbb{E}[\theta_k | \mathcal{D}] = \frac{\alpha_k + N_k}{N + \sum_{k=1}^K \alpha_k}. \end{aligned}$$

Agenda

- ① Modelo beta-binomial
- ② Modelo Dirichlet-multinomial
- ③ Classificador naive Bayes
- ④ Tópicos adicionais
- ⑤ Referências

Classificador naive Bayes

- Em uma tarefa de classificação com C classes, podemos considerar uma distribuição $p(\mathbf{x}|y = c)$ para os padrões da classe c .
- O **classificador naive Bayes** parte da suposição de independência dos atributos do padrão \mathbf{x} condicionados à classe:

$$p(\mathbf{x}|y = c, \boldsymbol{\theta}) = \prod_{d=1}^D p(x_d|y = c, \boldsymbol{\theta}_{dc}),$$

em que $\boldsymbol{\theta}$ coleciona os parâmetros do modelo e $\boldsymbol{\theta}_{dc}$ indica os parâmetros referentes ao d -ésimo atributo da classe c .

Classificador naive Bayes

- Temos as seguintes opções para $p(x_d|y = c, \boldsymbol{\theta}_{dc})$:
 - No caso de atributos reais, podemos usar uma distribuição Gaussiana $p(x_d|y = c, \boldsymbol{\theta}_{dc}) = \mathcal{N}(x_d|\mu_{dc}, \sigma_{dc}^2)$;
 - No caso de atributos binários, podemos usar uma distribuição de Bernoulli $p(x_d|y = c, \theta_{dc}) = \text{Ber}(x_d|\theta_{dc})$.
 - No caso de atributos categóricos no formato 1-of-K, podemos usar uma distribuição multinomial/categórica $p(\mathbf{x}_d|y = c, \boldsymbol{\theta}_{dc}) = \text{Cat}(\mathbf{x}_d|\boldsymbol{\theta}_{dc}) = \prod_{k=1}^K \theta_{dc k}^{x_{dk}}$.
- Note que podemos escolher outras distribuições e/ou combinar diferentes distribuições para diferentes atributos.

Classificador naive Bayes

- Sendo $\boldsymbol{\pi} = [\pi_1, \dots, \pi_c]^\top$ o vetor de probabilidades a priori das classes, podemos escrever a verossimilhança do modelo:

$$p(\mathbf{X}, \mathbf{y} | \boldsymbol{\theta}) = \prod_{i=1}^N p(y_i | \boldsymbol{\pi}) \prod_{d=1}^D p(x_{id} | y_i, \boldsymbol{\theta}_d)$$

$$p(\mathcal{D} | \boldsymbol{\theta}) = \prod_{i=1}^N \prod_{c=1}^C \pi_c^{\mathbb{I}(y_i=c)} \prod_{d=1}^D \prod_{c=1}^C p(x_{id} | \boldsymbol{\theta}_{dc})^{\mathbb{I}(y_i=c)}$$

$$\log p(\mathcal{D} | \boldsymbol{\theta}) = \sum_{c=1}^C N_c \log \pi_c + \sum_{i|y_i=c} \sum_{d=1}^D \sum_{c=1}^C \log p(x_{id} | \boldsymbol{\theta}_{dc}),$$

em que N_c é o número de exemplos da classe c .

Classificador naive Bayes

- A solução ML para π_c é dada por $\hat{\pi}_c = \frac{N_c}{N}$.
- A solução ML para os demais parâmetros depende da distribuição condicional escolhida para os atributos:

→ No caso de Gaussianas $p(x_d|y=c, \theta_{dc}) = \mathcal{N}(x_d|\mu_{dc}, \sigma_{dc}^2)$:

$$\hat{\mu}_{dc} = \frac{1}{N_c} \sum_{i|y_i=c} x_{id},$$

$$\hat{\sigma}_{dc}^2 = \frac{1}{N_c - 1} \sum_{i|y_i=c} (x_{id} - \hat{\mu}_{dc})^2.$$

→ No caso Bernoulli $p(x_d|y=c, \theta_{dc}) = \text{Ber}(x_d|\theta_{dc})$:

$$\hat{\theta}_{dc} = \frac{\sum_{i|y_i=c} \mathbb{I}(x_{id} = 1)}{N_c} = \frac{N_{dc}}{N_c}.$$

→ No caso categórico $p(\mathbf{x}_d|y=c, \theta_{dc}) = \text{Cat}(\mathbf{x}_d|\theta_{dc})$:

$$\hat{\theta}_{dck} = \frac{\sum_{i|y_i=c} \mathbb{I}(x_{idk} = 1)}{N_c} = \frac{N_{dck}}{N_c}.$$

Classificador naive Bayes - inferência Bayesiana

- Alternativamente, podemos seguir uma abordagem Bayesiana e escolher uma priori fatorada para os parâmetros $p(\boldsymbol{\theta})$:

$$p(\boldsymbol{\theta}) = p(\boldsymbol{\pi}) \prod_{d=1}^D \prod_{c=1}^C p(\theta_{dc}).$$

- Para atributos binários, i.e., verossimilhanças de Bernoulli, escolhemos as priori conjugadas abaixo:

$$p(\boldsymbol{\pi}) = \text{Dir}(\boldsymbol{\pi}|\boldsymbol{\alpha}), \quad p(\theta_{dc}) = \text{Beta}(\theta_{dc}|a, b).$$

- As posteriores seguem os modelos beta-binomial e Dirichlet-multinomial:

$$p(\boldsymbol{\theta}|\mathcal{D}) = p(\boldsymbol{\pi}|\mathcal{D}) \prod_{d=1}^D \prod_{c=1}^C p(\theta_{dc}|\mathcal{D}),$$

$$p(\boldsymbol{\pi}|\mathcal{D}) = \text{Dir}(N_1 + \alpha_1, \dots, N_C + \alpha_C),$$

$$p(\theta_{dc}|\mathcal{D}) = \text{Beta}(N_{dc} + a, N_c - N_{dc} + b).$$

Classificador naive Bayes - predições

- Dado um novo padrão x_* , devemos computar a distribuição preditiva para cada classe:

$$p(y_* = c | \mathbf{x}_*, \boldsymbol{\theta}) \propto p(y_* = c | \boldsymbol{\pi}) \prod_{d=1}^D p(x_{*d} | y_* = c, \theta_{dc}).$$

- A abordagem Bayesiana busca marginalizar $\boldsymbol{\theta}$ usando as distribuições a posteriori $p(\boldsymbol{\pi} | \mathcal{D})$ e $p(\theta_{dc} | \mathcal{D})$. Considerando atributos x_d binários:

$$\underbrace{p(y_* = c | \mathbf{x}_*, \mathcal{D})}_{\int p(y_* = c | \mathbf{x}_*, \boldsymbol{\theta}) p(\boldsymbol{\theta} | \mathcal{D}) d\boldsymbol{\theta}} \propto \underbrace{\text{Cat}(y_* = c | \boldsymbol{\pi}) p(\boldsymbol{\pi} | \mathcal{D}) d\boldsymbol{\pi}}_{p(y_* = c | \mathcal{D})} \\ \underbrace{\prod_{d=1}^D \int \text{Ber}(x_{*d} | y_* = c, \theta_{dc}) p(\theta_{dc} | \mathcal{D}) d\theta_{dc}}_{p(x_{*d} | y_* = c, \mathcal{D})}$$

Classificador naive Bayes - previsões

- A partir dos modelos conjugados anteriores, denotando $\bar{\pi}_c = \mathbb{E}[\pi_c | \mathcal{D}]$ e $\bar{\theta}_{dc} = \mathbb{E}[\theta_{dc} | \mathcal{D}]$, a preditiva também é analítica:

$$p(y_* = c | \mathbf{x}_*, \mathcal{D}) \propto \bar{\pi}_c \prod_{d=1}^D (\bar{\theta}_{dc})^{\mathbb{I}(x_{*d}=1)} (1 - \bar{\theta}_{dc})^{\mathbb{I}(x_{*d}=0)},$$

$$\bar{\theta}_{dc} = \frac{N_{dc} + b}{N_c + a + b},$$

$$\bar{\pi}_c = \frac{N_c + \alpha_c}{N + \sum_{c=1}^C \alpha_c}.$$

- A classe predita \hat{y}_* será dada por:

$$\hat{y}_* = \arg \max_c \left[\bar{\pi}_c \prod_{d=1}^D (\bar{\theta}_{dc})^{\mathbb{I}(x_{*d}=1)} (1 - \bar{\theta}_{dc})^{\mathbb{I}(x_{*d}=0)} \right].$$

Classificador naive Bayes - predições

- Por conveniência numérica, aplicamos uma função logarítmica na expressão à direita:

$$\begin{aligned}\hat{y}_* &= \arg \max_c \log \left[\bar{\pi}_c \prod_{d=1}^D (\bar{\theta}_{dc})^{\mathbb{I}(x_{*d}=1)} (1 - \bar{\theta}_{dc})^{\mathbb{I}(x_{*d}=0)} \right] \\ &= \arg \max_c \left[\log \bar{\pi}_c + \sum_{d|x_{*d}=1} \log \bar{\theta}_{dc} + \sum_{d|x_{*d}=0} \log(1 - \bar{\theta}_{dc}) \right].\end{aligned}$$

Agenda

- ① Modelo beta-binomial
- ② Modelo Dirichlet-multinomial
- ③ Classificador naive Bayes
- ④ Tópicos adicionais
- ⑤ Referências

Tópicos adicionais

- Família exponencial.

→ Distribuições que podem ser escritas no formato abaixo:

$$p(\mathbf{x}|\boldsymbol{\eta}) = h(\mathbf{x})g(\boldsymbol{\eta}) \exp(\boldsymbol{\eta}^\top \mathbf{u}(\mathbf{x})),$$

em que $\boldsymbol{\eta}$ são os chamados **parâmetros naturais** da distribuição, $h(\cdot)$, $g(\cdot)$ e $\mathbf{u}(\cdot)$ são funções do vetor \mathbf{x} .

→ O termo $g(\boldsymbol{\eta})$ normaliza a distribuição e é dado por:

$$g(\boldsymbol{\eta}) \int h(\mathbf{x}) \exp(\boldsymbol{\eta}^\top \mathbf{u}(\mathbf{x})) d\mathbf{x} = 1,$$

em que a integral é substituída por um somatório caso \mathbf{x} seja discreto.

→ Além de várias propriedades importantes, a família exponencial é a única família de distribuições que admite priori conjugada.

- Modelos não-conjugados.

Agenda

- ① Modelo beta-binomial
- ② Modelo Dirichlet-multinomial
- ③ Classificador naive Bayes
- ④ Tópicos adicionais
- ⑤ Referências

Referências bibliográficas

- Cap. 3 - MURPHY, Kevin P. **Machine learning: a probabilistic perspective**, 2012.
- Cap. 2 - BISHOP, Christopher M. **Pattern recognition and machine learning**, 2006.